접수번호	※작성하지 않음

「2024년 통계데이터 활용대회」데이터분석 보고서

제 목	국내 관광산업의 비주류 지역 기반 소멸 위기 지역 선정 및 예방 정책 제안

신 청 자 명	소속/직위	국민대학교	성 명	이유진
	휴대전화	010-4517-7921	전자우편	iamlyj03@kookmin.ac.kr
제출일	2024.07.16			

국내 관광산업의 비주류 지역 기반 소멸 위기 지역 선정 및 예방 정책 제안

1. 배경

□ 주제 선정

최근 한국의 저출산으로 인한 인구감소와 대도시 인구 집중으로 지방은 소멸 위기에 처해 있다. 지역관광 육성은 경제적 효과와 함께 관계 인구 창출로 인구 유입 가능성을 높이는 인구 정책 목적 달성도 가능하다.

□ 분석 필요성(문제점) 및 전략

본 조는 이러한 지역소멸에 관심을 가졌다. 이에 관광객이 각종 변수에 어떤 영향을 받는지, 그리고 그 미래를 예측하고 관광객 소멸 지역을 선정하는 연구는 된 바가 없다. 이번 연구를 통해 관광객 소멸 지역을 선정하여, 해당 지역에 관심을 기울이길 바라는 바이다.

2. 데이터 분석

□ 데이터 선정(사용한 데이터 및 이유 등)

보고서에서 사용한 데이터는 모두 2023년 기준으로 수집된 데이터이다. 이 데이터들은 아래와 같은 이유로 선정했다. 단, 지역은 수도권(서울, 경기, 인천)을 제외하고 진행했다.

1. 지역별 방문자 수: 각 지역에서 발생한 방문자 수를 기록하여 지역 간 관광 인기를 비교하고자 한다. (https://datalab.visitkorea.or.kr/datalab/portal/bda/getMetcoAna.do)
2. 지역별 관광지 검색건수: 각 지역 관광지에 대한 온라인 검색 활동을 통해 관심도를 파악하고, 관광 수요를 추정하고자 한다. (https://datalab.visitkorea.or.kr/datalab/portal/bda/getDomIngCnt.do)
3. 모바일 인구 이동량: 각 지역을 방문하는 관광객의 출발지와 이동 동향을 파악하여 지역 간 관계를 분석하고자 한다. (https://data.kostat.go.kr/nowcast/main.do?initId=19)
4. 지역별 신용카드 지출액: 관광 지출 패턴을 분석하여 지역 경제 활성화의 지표로 활용하고자 한다. (https://datalab.visitkorea.or.kr/datalab/portal/bda/getByLocgoCnsmAmt.do)
5. 지역별 숙박업소 개수: 관광 인프라 수준을 평가하고, 숙박 업소의 부족 지역을 식별하고자 한다. (https://www.bigdata-culture.kr/bigdata/user/data_market/detail.do?id=81ae75f0-497f-11ea-8aab-85ba209ddf37)
6. 지역별 관광지 검색순위: 각 관광지의 인기도를 순위로 나타내어 관심 지역과 인기 지역을 비교하고자 한다. (https://datalab.visitkorea.or.kr/datalab/portal/bda/getTourVisitCnt.do) 그러나, 해당 데이터가 전체 지역을 포함하지 않아 분석 결과에 부정적인 영향을 줄 것이라 판단하여 제외하기로 했다.
7. 사람들의 국내 여행 횟수: 개인의 여행 습관을 이해하고, 지역 관광 촉진 방안을 제안하고자

한다. (https://datalab.visitkorea.or.kr/datalab/portal/ts/getDomTourExmn.do)
8. 관광명소 이름과 위치 데이터: 관광 명소의 위치 정보를 통해 지역별 관광 리소스를 분석하고, 접근성을 평가하고자 한다. (https://www.bigdata-culture.kr/bigdata/user/data_market/detail.do?id=1ec19f06-035e-49f3-8c5d-ff8d2d2829a7)
9. 지역별 SNS 언급량 데이터: 각 지역이 SNS에 언급된 정도 및 소비자의 관심도를 알아보고자 한다. (https://datalab.visitkorea.or.kr/datalab/portal/loc/getAreaDataForm.do#)

□ 데이터 분석 (분석 프로세스, 분석 방법, 접근방법 등)

1. 상관분석

1-1. 분석 과정

지역별 방문자 수와 상관관계가 있는 변수를 판별하기 위해 상관분석을 진행했다. 종속변수는 방문자 수로 두었고, 그 외 데이터는 독립변수로 두었다. 단, 방문자 수 데이터의 방문자 구분을 전체 방문자로 한정하여 분석을 진행했다.

1-2. 분석 결과

분석 결과 검색 건수, SNS 언급량, 관외 이동량이 방문자 수와 강한 양의 상관관계를, 숙박업소 개수가 방문자 수와 약한 양의 상관관계를 나타냈다. 구체적인 상관계수와 p-value 수치는 <그림 1>을 통해 확인할 수 있다.

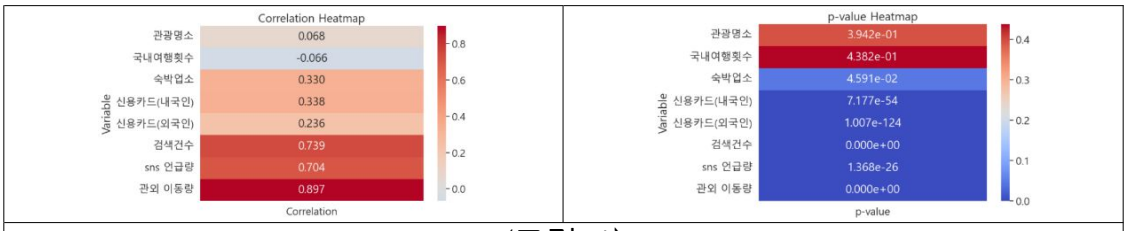

<그림 1>

2. 클러스터링

앞서 진행한 상관분석 결과에 따라 위의 4가지 변수들을 피처로 K-Means 클러스터링을 진행했다. 이때 방문자 수에 2배 가중치를 부여하고 데이터를 표준화한 후, 주어진 데이터를 2개의 클러스터로 분류했다.

주류 지역	비주류 지역
'강릉시', '속초시', '원주시', '춘천시', '거제시', '양산시', '창원시 성산구', '경주시', '구미시', '광주광역시 광산구', '광주광역시 북구', '광주광역시 서구', '대구광역시 달서구', '대구광역시 동구', '대구광역시 북구', '대구광역시 수성구', '대구광역시 중구', '대전광역시 서구', '대전광역시 유성구', '대전광역시 중구', '부산광역시 강서구', '부산광역시 기장군', '부산광역시 동래구', '부산광역시 수영구', '울산광역시 남구', '울산광역시 울주군', '순천시', '여수시', '군산시', '서귀포시', '제주시', '아산시', '천안시 동남구', '천안시 서북구', '태안군', '청주시 흥덕구'	그 외 지역

클러스터링 결과를 주류는 빨간색, 비주류를 파란색으로 표시하여 GeoJSON 데이터를 이용해 <그림 2>와 같이 지도에 시각화했다. 주류 지역의 경우 실제로 방문자 수가 많고, 관광지 밀집도가 높은 것을 확인했다.

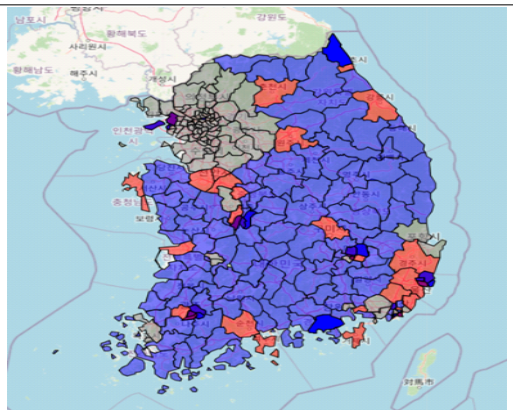

<그림 2>

3. 통합 데이터셋 구성(전처리)

예측 모델을 구축하기 위해 상관관계가 있는 변수 4개와 방문자 수를 합쳐 하나의 데이터셋으로 구성했다. 시계열 분석을 하기 위해 '일시' 컬럼을 만들어 'm' 형태로 두었다. 각 데이터프레임 간 공통 키값을 기준으로 교집합을 수행했다.

4. 예측 모델 구축

4-1. 회귀기법 선정

회귀 기법 중 LSTM, Random Forest, XGBoost을 선정하여 초기 예측 모델을 구축했다. 모두 공통적으로 검색 건수, 관외 이동량, 숙박업소 개수, sns를 독립변수로 두고, 방문자 수를 종속변수로 두었다.

4-2. LSTM

MinMaxScaler를 이용하여 데이터 스케일링을 진행한 뒤 시계열 데이터를 LSTM 입력 형식에 맞게 변환했다. 개선 모델 1은 LSTM 유닛 수와 드롭아웃 비율의 다양한 조합을 시도하며 가장 낮은 MSE를 기록한 것을 최적의 하이퍼파라미터로 선택했다. 개선 모델 2는 이의 자동화를 위해 'GridSearchCV'를 사용하여 교차 검증을 통해 최적의 조합을 찾고자 했다. 앞선 3가지 모델의 성능 평가지표의 결과는 <표 1>과 같으며, 이 중 '개선한

LSTM 1 ’ 을 가장 우수한 LSTM 모델로 선정했다.

	개선 전	개선 후 모델1	개선 후 모델2
MSE	9032281919743.375	8922515069093.088	9486957705864.871
MAE	2301321.688976378	2256638.8887795275	2380572.9082167833
R Squared	0.1519415267597255	0.1622477493291734	0.167546191628676
Accuracy	15.03%	15.58%	16.75%

〈표 1〉

4-3. Random Forest

기본 랜덤 포레스트 모델을 구축했을 때의 성능 지표는 〈표 2〉와 같다. 개선 후 모델1을 구축하고자 GridSearchCV를 사용하여 총 216개의 하이퍼 파라미터 조합을 만들어 학습시켰다. 또한, 5-폴드 교차 검증을 수행했다.
초기 모델과 비교한 결과 오히려 성능이 조금씩 떨어졌다. 따라서, 개선 후 모델2는 데이터 스케일링을 추가하고 데이터 표준화를 진행했다. 데이터 스케일링을 추가한 후에도 모델의 성능이 기대보다 떨어지는 결과를 얻었다. 개선 모델 1과 2의 성능 지표는 〈표 2〉와 같다.

	개선 전	개선 후 모델1	개선 후 모델2
MSE	515798428050.42896	532990370633.0028	528013106261.6215
MAE	437062.69509043935	450325.7391705384	450057.6233204135
R Squared	0.9537876451844897	0.9522473532654222	0.952693285425414
Accuracy	95.38%	95.22%	95.27%

〈표 2〉

4-4. XGBoost

초기 XGBoost 모델의 성능은 〈표 3〉과 같다. 이선구, 유선종의 연구를 참조하여 개선 모델 1은 n_estimators 값을 100, 200, 300, 400, 500으로, max_depth 값을 3, 5, 7으로, learning_rate의 값은 0.1, 0.01, 0.001으로 설정했다. 개선 모델 2는 이 3가지 변수 외에 subsample 변수도 추가하여 성능을 개선해 보았다. 최종적으로 개선 모델의 성능은 〈표 3〉과 같다.

	개선 전	개선 후 모델1	개선 후 모델2
MSE	485589919633.972	448159916009.0625	436425240254.39825
MAE	438032.69444444444	408967.08244509046	412545.4827600129
R Squared	0.9564941410430854	0.9598476382896707	0.960898992791989
Accuracy	95.65%	95.98%	96.09%

〈표 3〉

4-5. 최종 모델 선택

위와 같은 기법으로 구축한 총 9가지 모델을 비교했다. 각 기법별 성능이 좋은 모델을 뽑아 비교한 결과는 〈표 4〉와 같다.

	LSTM	Random Forest	XGBoost
MSE	8922515069093.088	515798428050.43	436425240254.39825
MAE	2301321.688976378	437062.69	412545.4827600129
R Squared	0.151941526759255	0.953788	0.960898992791989
Accuracy	15.03%	95.38%	96.09%

〈표 4〉

따라서 본 조는 9개 성능 모델 중에서 4가지 하이퍼파라미터를 최적화하는 XGBoost 방법을 최종 모델로 선택했다. 오재영 외 3인의 연구에 따르면, XGBoost의 하이퍼파라미터를 개선하기 위해 이를 최적화시키는 방법으로는 격자 탐색, 랜덤 탐색, 베이지안 최적화를 소개하고 있다.

이 3가지 방법을 가지고 최적의 하이퍼파라미터를 구하고자 했다. n_estimators 값을100, 500, 1000으로, max_depth 값을 3, 5, 7으로, learning_rate의 값은 0.01, 0.05, 0.1으로, subsample는 0.6, 0.8, 1.0으로 설정하여 진행했다. 그 성능의 결과는 〈표 5〉과 같고, grid search 방법으로 생성한 모델의 성능이 가장 우수하다.

	grid search	random search	Bayesian optimization
MSE	433796369727.71204	436425240254.39825	550869990839.221
MAE	407997.6662225452	412545.4827600129	449024.5050872093
R Squared	0.9611345233615614	0.960898992791989	0.9506454496767289
Accuracy	96.11%	96.08%	95.06%

〈표 5〉

□ 분석 결과 및 해석

1. 2024년 1월~5월의 지역별 방문자 수 예측

최종 XGBoost 모델을 가지고 2024년의 1월부터 4월까지의 지역별 방문자 수를 예측했다. 예측 방문자 수와 2024년 1월부터 4월까지의 실제 방문자 수를 비교하여 모델의 실제 성능을 평가했다. 월별로 오차 평균값은 1월 643,232.75, 2월 603,897.88, 3월 354,379.94, 4월 344,070.74로 산출됐다.

2. 방문자 소멸 위기 지역 선정

ARIMA 모델을 이용해 예측한 2025년도의 각 변숫값을 가지고 XGBoost 모델을 통해 2025년도의 지역별 방문자 수를 예측했다. 2023년도, 2024년도, 2025년도 각각 1월의 방문자 수를 기준으로 지역별 방문자 수 감소율을 측정했다.

$감소율 = \left(\frac{방문자\ 수_{2025} - 방문자\ 수_{2023}}{방문자\ 수_{2023}}\right) \times 100$	지역명 감소율 100 전라남도 담양군 230.803502 57 경상북도 울릉군 210.430753 71 대구광역시 군위군 103.009420 112 전라남도 장성군 92.065391 133 충청남도 공주시 68.777334
〈식 1〉	〈그림 4〉

감소율이 가장 높은 5개의 지역으로는 담양군, 울릉군, 군위군, 장성군, 공주시가 뽑혔다. 이 지역 중 4개의 지역은 실제로 클러스터링 진행 시 비주류 지역으로 선정되었던 지역이다. 본 조는 이 지역들을 소멸 위기 지역으로 제안한다.

3. 분석 활용 전략

□ 기대효과

소멸 위기 지역을 공표함으로써 해당 지역 기관들에 위기의식 및 정책 수립 필요성을 환기할 수 있으며 이는 지역의 지속 가능한 발전을 위한 기반을 마련하는 데 이바지할 것이다. 소멸 위기 지역의 특성을 고려한 관광 상품 개발과 홍보 전략 수립 등을 통해 지역 경제 활성화까지 이끌어낼 수 있으며, 이 또한 해당 지역의 소멸 위기를 극복하는 데 큰 도움이 될 것이다.

□ 방향 제시

분석 결과 최종적으로 “소멸 위기 지역”으로 선정된 지역들을 관계 부처와 지자체에 공식적으로 공표하고, 해당 지역의 특징을 고려한 맞춤형 정책 시행 및 예산 지원을 요청할 것이다. 선정된 지역의 주민들에게 소멸 위기의 심각성을 알리고, 인구 유입을 위한 다양한 정책을 제안하는 등의 노력으로 위기를 극복할 수 있도록 한다.

참고문헌

이선구,유선종(2024). XGBOOST 모형을 활용한 부동산 조각투자 가격 예측: 카사TE 물류센터를 중심으로. 6, 15-16

오재영 외 3인(2019). XGBoost 기법을 이용한 단기 전력 수요 예측 및 하이퍼파라미터 변화에 따른 영향 분석. 2-3